GUÍA DE ESTUDIO I (PROBABILIDAD Y ESTADÍSTICA)

El objetivo de este documento es servir de guía para les estudiantes en su preparación para los parciales del curso. Los enunciados marcados con Lema o Teorema son fundamentales y hay que conocer sus demostraciones.

1. Definiciones básicas

Notación. Usaremos los conceptos de unión, intersección e inclusión de conjuntos. Para dos conjuntos A, B escribiremos $AB := A \cap B$ para simplificar las fórmulas.

Definición 1.1. Un *espacio de probabilidad* es una tripla $(\Omega, \mathscr{F}, \mathbb{P})$ donde:

(1) Ω es un conjunto cualquiera, llamado *espacio muestral*
(2) $\mathscr{F}$ es una *sigma-algebra* de subconjuntos de Ω, es decir una colección de subconjuntos que cumple las siguientes condiciones:
   (a) (*No vacuidad*) $\Omega \in \mathscr{F}$
   (b) (*Cerradura bajo complementos*) $A \in \mathscr{F}$ entonces $\overline{A} \in \mathscr{F}$ donde $\overline{A} := \Omega \setminus A$.
   (c) (*Cerradura bajo uniones contables*) Si $\{A_n\}_{n\in\mathbb{N}}$ es una colección de conjuntos con $A_j \in \mathscr{F}$ entonces $\bigcup_{n\in\mathbb{N}} A_j \in \mathscr{F}$.
(3) $\mathbb{P}$ es una *medida de probabilidad*, es decir una función $\mathbb{P} : \mathscr{F} \to \mathbb{R}$ que cumple:
   (a) (*no-negatividad*) $\forall A \in \mathscr{F}\ (\mathbb{P}(A) \geqslant 0)$
   (b) (*máximo uno*) $\mathbb{P}(\Omega) = 1$
   (c) (*es σ-aditiva sobre conjuntos disjuntos*) Si $A_j,\ j = 1, 2, 3, \ldots$ es una colección de conjuntos disjuntos (i.e. si $A_i \cap A_j = \emptyset$ para $i \neq j$) con $A_j \in \mathscr{F}$ entonces

$$\mathbb{P}\left(\bigcup_{j=0}^{\infty} A_j\right) = \sum_{j=0}^{\infty} \mathbb{P}(A_j)$$

Los axiomas de arriba permiten deducir propiedades que se cumplen en todos los espacios de probabilidad. El siguiente Lema contiene algunas de esas propiedades (intente demostrarlas para verificar su entendimiento de los axiomas básicos)

Lemma 1.2. *Sea $(\Omega, \mathscr{F}, \mathbb{P})$ un espacio de probabilidad. Demuestre que las siguientes propiedades se cumplen:*

(1) Para todo $A \in \mathscr{F}$ se tiene $\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A)$
(2) Si $A, B \in \mathscr{F}$ con $A \subseteq B$ entonces $\mathbb{P}(A) \leqslant \mathbb{P}(B)$. En particular la probabilidad de cualquier evento $A \in \mathscr{F}$ cumple $\mathbb{P}(A) \leqslant 1$.
(3) Para todos $A, B \in \mathscr{F}$ se tiene que

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Más generalmente si A, B, C son tres eventos cualquiera se tiene que

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - (\mathbb{P}(AB) + \mathbb{P}(AC) + \mathbb{P}(BC)) + \mathbb{P}(ABC)$$

*(4) (*Union bound*) Si $A_1, A_2, \cdots \in \mathscr{F}$ son una colección cualquiera de eventos, entonces*

$$\mathbb{P}\left(\bigcup_{j=1}^{\infty} A_j\right) \leqslant \sum_{j=1}^{\infty} \mathbb{P}(A_j).$$

1.1. **Ejemplo 1: La probabilidad clásica ó la medida Uniforme sobre conjuntos finitos.** Si Ω es un conjunto finito cualquiera definimos $\mathscr{F}$ como la colección de todos los subconjuntos de Ω y $\mathbb{P}(A) := \frac{|A|}{|\Omega|}$ para cualquier subconjunto $A \subseteq \Omega$. Es fácil verificar que $(\Omega, \mathscr{F}, \mathbb{P})$ es un espacio de probabilidad llamado *probabilidad uniforme en* Ω. Por definición la probabilidad uniforme se calcula contando cuántos casos favorables hay $|A|$ y dividiéndolo sobre el número de casos totales $|\Omega|$. La rama de las matemáticas que se ocupa de contar se llama combinatoria. Para poder resolver problemas de conteo necesitamos algunos fundamentos de combinatoria que resumimos a continuación en las

Reglas de conteo:

(1) (*principio del producto*) Si un proceso se realiza en n etapas y hay a_1 maneras para realizar la primera etapa, a_2 maneras de realizar la segunda (independientemente de la primera elección), a_3 maneras de realizar la tercera (independientemente de las primeras dos elecciones), etc. entonces el número total de maneras de realizar el proceso es el producto

$$a_1 \cdot a_2 \cdot \cdots \cdot a_n$$

(2) (*principio de la suma*) Si A, B son conjuntos disjuntos entonces

$$|A \cup B| = |A| + |B|$$

El siguiente Lema contiene algunas propiedades básicas de combinatoria que usaremos de ahora en adelante. Demuéstrelo para verificar su entendimiento de los principios

Lemma 1.3. *Las siguientes afirmaciones son ciertas:*

(1) El número de palabras de longitud n en los símbolos $1, 2, \ldots, k$ *es* k^n.

(2) El número de palabras de longitud n en los símbolos $1, 2, \ldots, k$ *en las que cada símbolo se usa a lo más una vez es*

$$k(k-1)(k-2)\ldots(k-n+1) = \frac{k!}{(k-n)!}$$

(3) El número de subconjuntos de tamaño k de un conjunto de n items, denotado $\binom{n}{k}$ *está dado por*

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Ejemplo 1.4. Una baraja consiste en 52 cartas. Cada carta tiene una pinta (diamantes, corazones, picas o tréboles) y en cada pinta tiene uno de trece símbolos $1, 2, \ldots, 10, J, Q, K$ (el uno también se llama As). Hay pintas de dos colores, rojas y negras: diamantes y corazones son rojas y las demás negras.

En el juego del Poker se reparten *uniformemente* 5 cartas a cada jugador. Calcule las probabilidades de que un jugador tenga cada una de las siguientes manos:

(1) *Un par*: exactamente dos cartas tienen el mismo símbolo y las otras tres cartas tienen símbolos distintos entre sí y distintos del símbolo del par.

(2) *Dos pares*: hay dos pares de cartas con el mismo símbolo, y la quinta carta tiene un símbolo distinto de los otros cuatro.
(3) *Trío*: exactamente tres cartas tienen el mismo símbolo y las otras dos cartas tienen símbolos distintos entre sí y distintos del símbolo del trío.
(4) *Escalera*: las cinco cartas tienen símbolos consecutivos, independientemente de sus pintas. En este caso, el As puede utilizarse como 1 en la secuencia $A,2,3,4,5$ o como la carta inmediatamente superior al Rey en $10,J,Q,K,A$.
(5) *Color*: las cinco cartas tienen la misma pinta, pero no forman una escalera.
(6) *Full*: tres cartas tienen el mismo símbolo y las otras dos cartas tienen otro símbolo en común.
(7) *Póker*: cuatro cartas tienen el mismo símbolo y la quinta carta tiene un símbolo diferente.
(8) *Escalera de color*: las cinco cartas tienen la misma pinta y sus símbolos son consecutivos. Incluye la escalera real $10,J,Q,K,A$.

1.2. **Ejemplo 2: Intentos de Bernoulli.** Los Bernoulli trials son un modelo probabilista para la siguiente situación: *Se lanzan n monedas independientemente. Cada una de las monedas tiene dos lados (llamados* 0 *y* 1*). Sabemos que la probabilidad de que cada moneda salga* 1 *es un número conocido* $p \in [0,1]$.

Para poder formalizar el concepto de independencia debemos entender cómo debe alterarse la probabilidad cuando sabemos que un evento B ha ocurrido. Esto está capturado por la probabilidad condicional $\mathbb{P}(A|B)$.

Definición 1.5. Si $B \in \mathscr{F}$ es un evento con $\mathbb{P}(B) > 0$ definimos, para cualquier $A \in \mathscr{F}$ la *probabilidad condicional de A dado B* mediante la fórmula

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Dos eventos A y B son $\mathbb{P}$- independientes si saber que B ocurrió no afecta la probabilidad de que A ocurra, es decir

$$\mathbb{P}(A|B) = \mathbb{P}(A)$$

Usando la definición de probabilidad condicional esto es equivalente a

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

Generalizando lo anterior definimos

Definición 1.6. Un conjunto de eventos $A_1,\ldots,A_n$ se dicen *eventos* $\mathbb{P}$*-independientes* si para cualquier subconjunto de índices $I \subseteq \{1,\ldots,n\}$ tenemos la igualdad

$$\mathbb{P}\left(\bigcap_{j\in I} A_j\right) = \prod_{j\in I} \mathbb{P}(A_j)$$

Observación 1.7. En la literatura en probabilidades típicamente se escribe *independientes* en lugar de $\mathbb{P}$-independientes. No obstante la independencia no solo depende de los eventos A,B sino también de la medida de probabilidad que estemos usando.

Ejemplo 1.8. (*Bernoulli trials*) Se lanzan n monedas independientemente. Cada una de las monedas tiene dos lados (llamados 0 y 1). Sabemos que la probabilidad de que cada moneda salga 1 es un número conocido $p \in [0,1]$.

Denotamos $q := 1 - p$. Describiremos un modelo probabilístico para los Bernoulli trials. Definimos $\Omega = \{0,1\}^n$ como el conjunto de palabras de longitud n en el conjunto de símbolos $\{0,1\}$. Una palabra $\omega \in \Omega$ describe completamente el resultado de los n lanzamientos. Si $n = 3$ la palabra $\omega = (1,1,0)$ dice que la primera y segunda moneda salieron 1 y la tercera cero. Definimos $\mathscr{F}$ como todos los subconjuntos de Ω. Para una palabra $\omega \in \Omega$ definimos

$$\mathbb{P}(\{\omega\}) = p^{n_1(\omega)} q^{n_0(\omega)}$$

donde $n_0(\omega)$ es el número de ceros en la palabra ω y $n_1(\omega)$ es el número de unos. Para los demás $A \in \mathscr{F}$ definimos $\mathbb{P}(A) := \sum_{\omega \in A} \mathbb{P}(\omega)$.

El siguiente Lema contiene las propiedades principales del modelo de Bernoulli.

Lemma 1.9. *Para $j = 1, \ldots, n$ defina $C_j := \{\omega \in \Omega : \omega_j = 1\}$. Las siguientes propiedades se cumplen en el $(\Omega, \mathscr{F}, \mathbb{P})$ definido anteriormente*

(1) $\mathbb{P}(C_j) = p$

(2) Los conjuntos C_j son eventos $\mathbb{P}$-independientes.

Más aún, existe una única medida de probabilidad $\mathbb{P}$ en $(\Omega, \mathscr{F})$ que satisface estas dos propiedades.

Teniendo una medida de probabilidad podemos calcular como se comporta cualquier cantidad que queramos medir sobre los n lanzamientos. Por ejemplo,

Lemma 1.10. *(*Distribución binomial*) Sea $S : \Omega \to \mathbb{R}$ el número de éxitos (cantidad de 1's) en los n lanzamientos. Para $k = 0, \ldots, n$ se tiene que*

$$\mathbb{P}\{\omega \in \Omega : S(\omega) = k\} := \binom{n}{k} p^k q^{n-k}$$

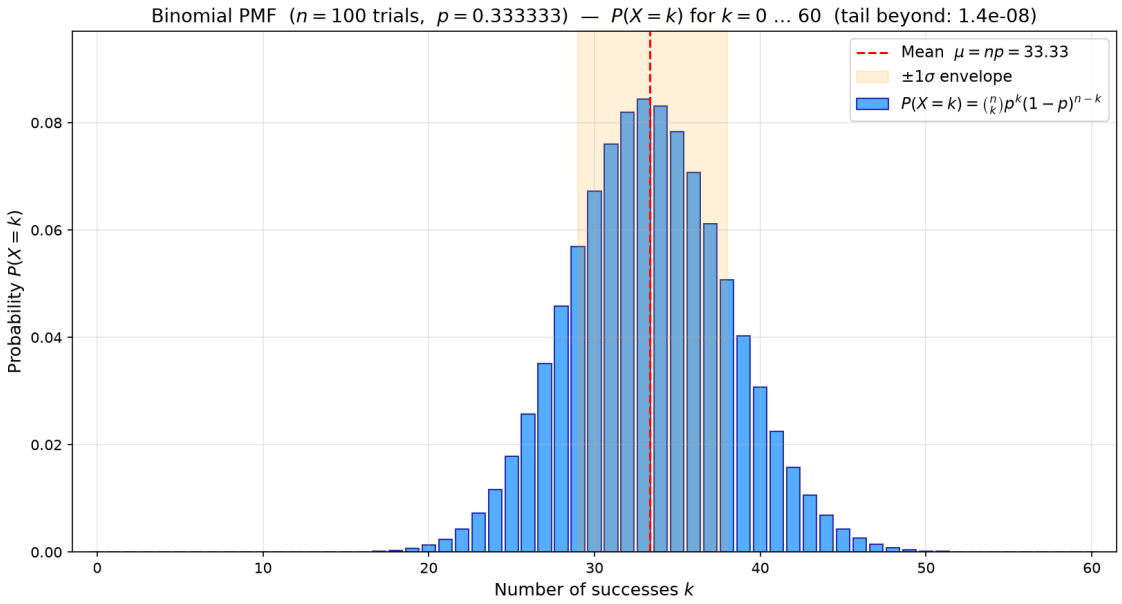


FIGURE 1. Función de masa de probabilidad de la distribución binomial con $n = 100$ y $p = \frac{1}{3}$: la probabilidad $\mathbb{P}\{S = k\} = \binom{100}{k}(1/3)^k(2/3)^{100-k}$ para $k = 0, \ldots, 60$, con la media $\mu = np \approx 33.33$.

1.3. **Aproximaciones para la distribución binomial.** Esta sección es una tangente del tema central del curso que sirve como motivación para algunas de las ideas que desarrollaremos después.

La siguiente fórmula provee una aproximación de la densidad binomial $\mu_n(m) := \binom{n}{m} p^m q^{n-m}$ mediante una función muy especial, la llamada *distribución normal o distribución Gaussiana* $\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ que juega un rol central en probabilidad y estadística.

Lemma 1.11. *Para todo $p \in (0,1)$ y $m = 0, \ldots, n$, definiendo $x = \frac{m-np}{\sqrt{npq}}$ se tiene que*

$$\lim_{n\to\infty} \frac{\sqrt{npq}\mu_n(m)}{\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}} = 1$$

Más precisamente el Lema anterior dice que

$$\mu_n(m) \approx \frac{1}{\sqrt{2\pi npq}} e^{-\frac{\left(\frac{m-np}{\sqrt{npq}}\right)^2}{2}}$$

provee buenas estimaciones cuando $n >> 0$ y p no es ni demasiado grande ni demasiado chico. Esto es muy útil pues el lado derecho es fácilmente aproximable numéricamente.

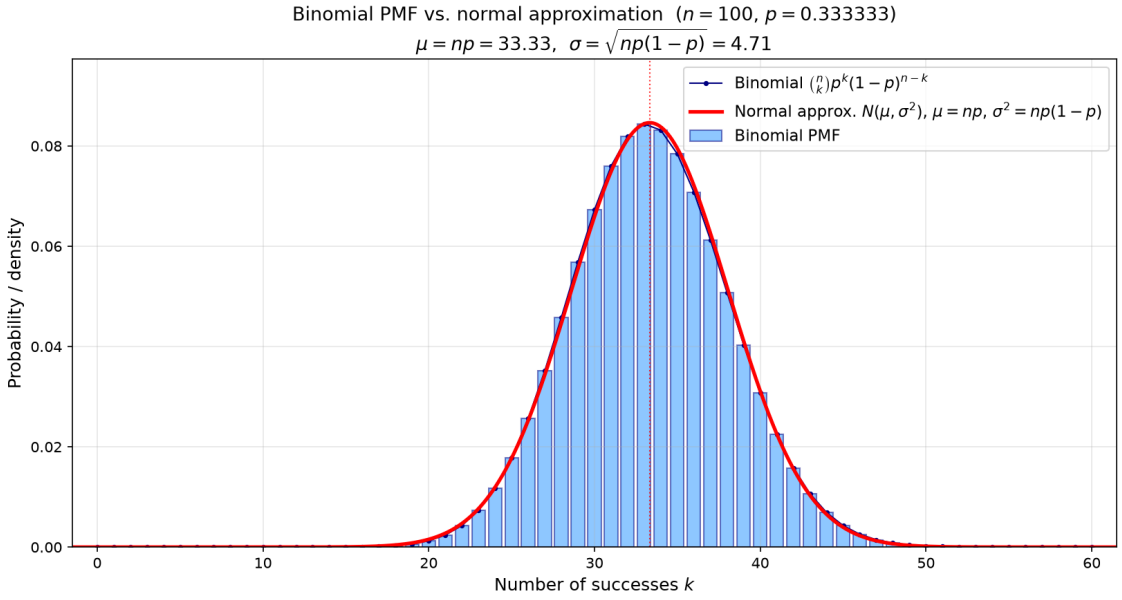


FIGURE 2. Función de masa de probabilidad de la distribución binomial con $n = 100$ y $p = \frac{1}{3}$ junto con su aproximación normal correspondiente.

1.4. **Ejemplo 3: Un espacio de probabilidad continuo.** Queremos construir un modelo probabilista para la siguiente situación: *Se selecciona un número real en el intervalo $[0,1]$ de manera uniforme (de tal forma que todo punto tenga la misma probabilidad).*

Definimos $\Omega = [0,1]$ y definimos $\mathscr{F}$ como la sigma-álgebra más pequeña que contiene a los intervalos abiertos $(a,b) \subseteq [0,1]$, esta sigma-álgebra se llama la sigma-álgebra de Borel. Definimos $\mathbb{P}((a,b)) := b-a$ para cualquier intervalo y más generalmente definimos la probabilidad de cualquier

$A \in \mathscr{F}$ como su longitud (también llamada su medida de Lebesgue). Es un hecho (no tan fácil de demostrar y parte de un curso más preciso) que $(\Omega, \mathscr{F}, \mathbb{P})$ es un espacio de probabilidad.

Observación 1.12. Bajo este modelo continuo de probabilidad $\mathbb{P}(\{z\}) = 0$ para cualquier $z \in [0,1]$. Por lo anterior el comportamiento de la probabilidad debe estudiarse en intervalos. Por ejemplo $\mathbb{P}([0,z]) = z$ para cualquier $z \in [0,1]$ y $\mathbb{P}([1/3, 2/3]) = 1/3$.

2. Variables aleatorias

En esta sección introducimos variables aleatorias en $\mathbb{R}$, sus distribuciones y sus valores esperados.

Definición 2.1. Una *variable aleatoria* X en $(\Omega, \mathscr{F}, \mathbb{P})$ es una función $X : \Omega \to \mathbb{R}$ tal que para todos $a, b \in \mathbb{R}$ el conjunto $\{\omega \in \Omega : a < X(\omega) \leqslant b\} \in \mathscr{F}$. La *distribución* de X es la función que mide la probabilidad de que X caiga en cada intervalo $(a,b]$

$$\mathbb{P}_X((a,b]) := \mathbb{P}(\{\omega \in \Omega : a < X(\omega) \leqslant b\})$$

Para simplificar la notación denotamos

$$\mathbb{P}(\{\omega \in \Omega : a < X(\omega) \leqslant b\}) =: \mathbb{P}\{a < X \leqslant b\}$$

Típicamente la distribución se resume a través de la *función de distribución acumulada*

$$F_X(\beta) := \mathbb{P}(\{\omega \in \Omega : X(\omega) \leqslant b\})$$

ó usando notación menos recargada $F_X(\beta) = \mathbb{P}\{X \leqslant \beta\}$.

Ejemplo 2.2. *Lanzamos dos monedas justas* $\{0,1\}$ *y definimos la variable* X *como el número de veces que cae* 1. Como vimos en la sección anterior, el espacio de probabilidad natural es el modelo de Bernoulli con $p = q = 1/2$ y $n = 2$. Es decir $\Omega = \{00, 01, 10, 11\}$, $\mathscr{F}$ son todos los subconjuntos de Ω y $\mathbb{P}$ es la distribución uniforme en Ω (que asigna $1/4$ a cada $\omega \in \Omega$). La función X se puede tabular así:

ω	$X(\omega)$
00	0
10	1
01	1
11	2

De lo anterior vemos que la distribución de X cumple: X cae 0 con prob $1/4$, cae 1 con probabilidad $1/2$ (pues es la suma de las probabilidades de las pre-imágenes 01 y 10 y cada una contribuye $1/4$) y cae 2 con probabilidad $1/4$.

Ejemplo 2.3. Si en el ejemplo anterior definimos Y como la cantidad de veces que cae cero entonces obtenemos una nueva variable aleatoria distinta de X pues $0 = X(00) \neq Y(00) = 2$ luego son funciones distintas. No obstante las variables X e Y tienen *la misma distribución*.

2.1. Distribuciones de probabilidad de variables aleatorias escalares.

Distinguimos variables aleatorias discretas y continuas. Luego de algunas definiciones preliminares nos ocuparemos del estudio de ejemplos concretos.

Definición 2.4. Sea $D \subseteq \mathbb{R}$ un conjunto discreto. Una función $f_X : D \to \mathbb{R}$ es la densidad de una variable aleatoria discreta X en D si cumple:

(1) $\forall d \in D\,(f_X(d) \geqslant 0)$

(2) $\sum_{d\in D} f_X(d) = 1$

La *función de distribución acumulada* de la variable discreta X es la función

$$F(\beta) := \sum_{d\in D: d\leqslant\beta} f_X(d)$$

El *valor esperado* de la variable X es el número

$$\mathbb{E}[X] := \sum_{d\in D} d f_X(d).$$

Sea $[a,b] \subseteq \mathbb{R}$ un intervalo (permitiendo $a = -\infty$ y $b = \infty$).

Definición 2.5. Una función $f_X : [a,b] \to \mathbb{R}$ es la densidad de una variable aleatoria absolutamente continua X en $[a,b]$ si cumple:

(1) $\forall x \in [a,b]\,(f_X(x) \geqslant 0)$

(2) $\int_a^b f_X(x)dx = 1$

La *función de distribución acumulada* de la variable absolutamente continua X es la función

$$F_X(\beta) := \int_a^\beta f_X(x)dx$$

El *valor esperado* de la variable X es el número

$$\mathbb{E}[X] := \int_a^b x f_X(x)\,dx$$

Notar que tanto en el caso discreto como el continuo la función $F_X(\beta) = \mathbb{P}\{X \leqslant \beta\}$.

2.2. **Ejemplos de variables aleatorias escalares (1*D*).** En esta subsección ilustramos algunas de las distribuciones de probabilidad más comunes para variables aleatorias escalares. En cada figura se marca la media $\mathbb{E}[X]$ con una línea vertical.

- *Distribución binomial*. La variable $X \sim \text{Binomial}(n,p)$ tiene densidad discreta para $k \in \{0,1,\ldots,n\}$ con $\mathbb{P}\{X = k\} = \binom{n}{k} p^k (1-p)^{n-k}$, media $\mathbb{E}[X] = np$ y varianza $\text{Var}(X) = np(1-p)$. En la figura se superponen dos casos distintos, Binomial$(40, \frac{1}{4})$ (media $np = 10$) y Binomial$(90, \frac{1}{3})$ (media $np = 30$), con el fin de apreciar el rango de formas que admite la familia binomial: la media np desplaza la distribución y los parámetros n y p determinan su dispersión.
- *Distribución de Poisson.* La variable $X \sim \text{Poisson}(\lambda)$ tiene distribución discreta en los enteros no negativos k con densidad $\mathbb{P}\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}$, media $\mathbb{E}[X] = \lambda$ y varianza $\text{Var}(X) = \lambda$. En la figura se superponen los casos $\lambda = 10$ y $\lambda = 20$, mostrando cómo λ desplaza la distribución y, al mismo tiempo, aumenta su dispersión (en Poisson, media y varianza coinciden, ambas iguales a λ).
- *Distribución gaussiana (normal).* La variable $X \sim \text{Normal}(\mu,\sigma)$ tiene densidad continua

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

media $\mathbb{E}[X] = \mu$ y varianza $\text{Var}(X) = \sigma^2$. En la figura se comparan Normal$(0,1)$, Normal$(0,2)$ y Normal$(3,1)$, observando el efecto de la media y de la desviación estándar.

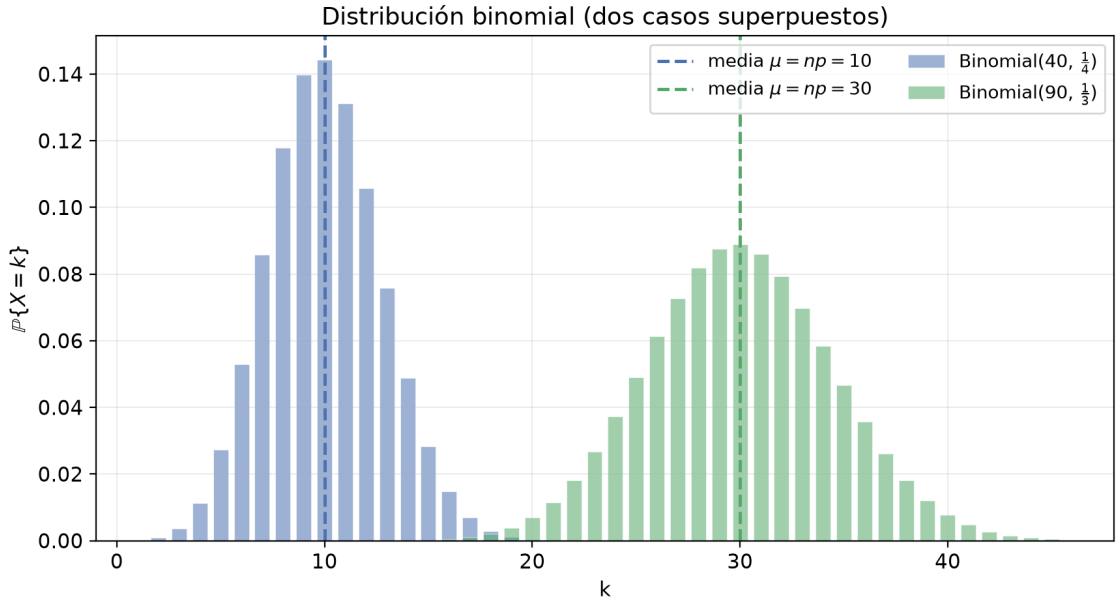


FIGURE 3. Función de masa de probabilidad de la distribución binomial, con dos casos superpuestos en el mismo gráfico: Binomial$(40, \frac{1}{4})$ (media $\mu = 10$) y Binomial$(90, \frac{1}{3})$ (media $\mu = 30$). Las líneas verticales discontinuas (una por cada curva) marcan la media de cada distribución.

2.3. **Vectores aleatorios.**

Definición 2.6. Un *vector aleatorio* (X,Y) en $\mathbb{R}^2$ en el espacio $(\Omega, \mathscr{F}, \mathbb{P})$ es una función $(X,Y) : \Omega \to \mathbb{R}^2$ tal que para todos $(\beta_1, \beta_2) \in \mathbb{R}^2$ se cumple que

$$\{\omega \in \Omega : X(\omega) \leqslant \beta_1 \text{ y simultáneamente } Y(\omega) \leqslant \beta_2\} \in \mathscr{F}.$$

La *densidad acumulada* de un vector aleatorio es la función

$$F_{(X,Y)}(\beta_1, \beta_2) := \mathbb{P}\{\omega \in \Omega : X(\omega) \leqslant \beta_1 \text{ y } Y(\omega) \leqslant \beta_2\}.$$

Decimos que un vector aleatorio (X,Y) tiene *densidad conjunta absolutamente continua* $f_{(X,Y)}(x,y)$ si para toda región R medible en el plano se cumple que

$$\mathbb{P}\{(X,Y) \in R\} := \iint_R f_{(X,Y)}(x,y)dA$$

y en particular

$$F_{(X,Y)}(\beta_1, \beta_2) = \int_{-\infty}^{\beta_1} \int_{-\infty}^{\beta_2} f_{(X,Y)}(x,y)dydx$$

Observación 2.7. De manera semejante definimos vectores aleatorios $(X_1, \ldots, X_d) \in \mathbb{R}^d$ sus distribuciones acumuladas y densidades conjuntas $f_{(X_1,\ldots,X_d)}(x_1, \ldots, x_d)$

Definición 2.8. La *distribución marginal* en X de un vector aleatorio (X,Y) es la distribución de la primera componente, es decir la distribución de los valores de X si ignoramos el valor de la segunda

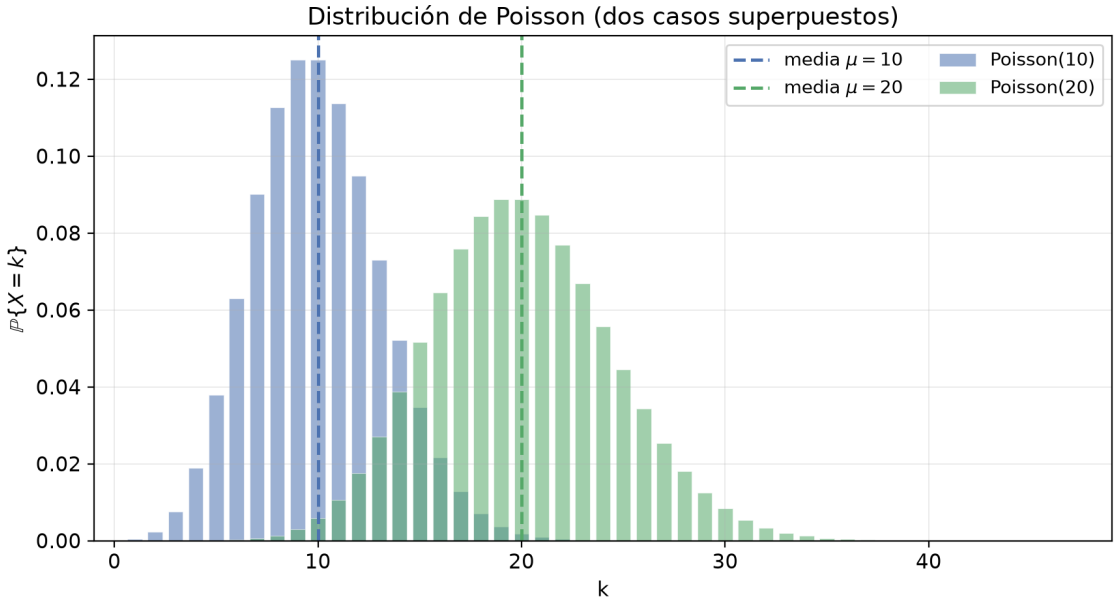


FIGURE 4. Función de masa de probabilidad de la distribución de Poisson, con dos casos superpuestos en el mismo gráfico: Poisson(10) (media $\mu = 10$) y Poisson(20) (media $\mu = 20$). Las líneas verticales discontinuas (una por cada curva) marcan la media de cada distribución.

componente. Es inmediato que podemos calcular la distribución acumulada y la densidad (marginal) de X mediante las fórmulas

$$F_X(\beta_1) := \int_{-\infty}^{\beta_1} \left(\int_{-\infty}^{\infty} f_{(X,Y)}(x,y)dy \right) dx$$

$$f_X(x) = \int_{-\infty}^{\infty} f_{(X,Y)}(x,y)dy.$$

De manera semejante podemos calcular las marginales de la variable Y integrando sobre todos los valores posibles de X.

Ejemplo 2.9. Una distribución conjunta no está determinada por sus distribuciones marginales. En el ejemplo vemos dos distribuciones gaussianas con las mismas marginales pero distintas distribuciones conjuntas. En la figura 6 se ven dos gaussianas bivariadas con marginales idénticas ($X \sim N(0,1)$ y $Y \sim N(0,1)$, curvas grises en la parte superior y en la derecha de cada panel) pero con distribución conjunta distinta: Como veremos más adelante es posible distinguir las distribuciones conjuntas mediante sus *coeficientes de correlación* $\rho = +0.8$ (izquierda) frente a $\rho = -0.8$ (derecha).

Bajo la hipótesis adicional de *independencia entre las componentes* un vector aleatorio queda completamente determinado por sus marginales. Más precisamente

Definición 2.10. Un vector aleatorio (X,Y) tiene componentes independientes si para todo rectángulo $[a,b] \times [c,d]$ tenemos la igualdad

$$\mathbb{P}\{(X,Y) \in [a,b] \times [c,d]\} = \mathbb{P}\{X \in [a,b]\}\,\mathbb{P}\{Y \in [c,d]\}$$

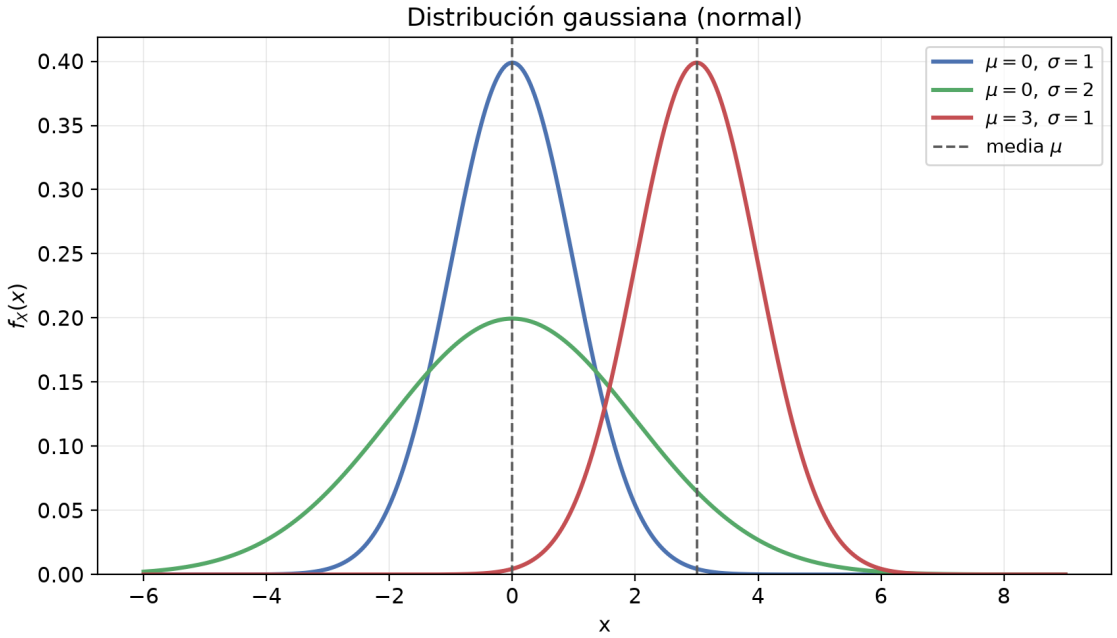


FIGURE 5. Función de densidad de la distribución gaussiana para $\mu = 0, \sigma = 1$; $\mu = 0, \sigma = 2$; y $\mu = 3, \sigma = 1$. Las líneas verticales marcan la media μ de cada distribución.

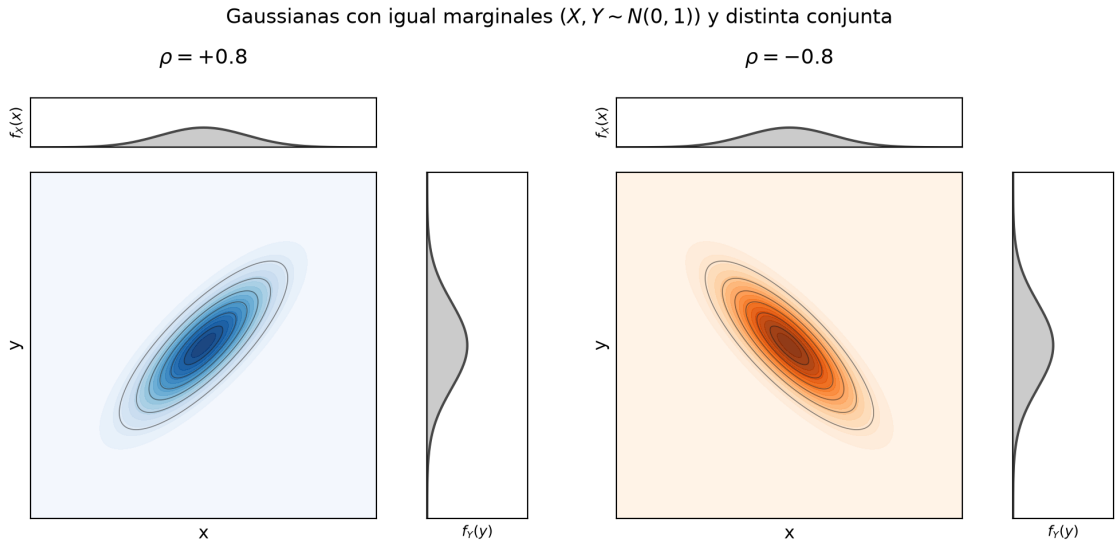


FIGURE 6. Dos distribuciones gaussianas conjuntas con las *mismas* marginales ($X \sim N(0,1)$ y $Y \sim N(0,1)$, curvas grises en la parte superior y en la derecha de cada panel) pero con distribución conjunta distinta: $\rho = +0.8$ (izquierda) y $\rho = -0.8$ (derecha). La distribución conjunta no queda determinada por sus distribuciones marginales.

Como la condición de arriba depende de todos los rectángulos podría parecer que verificar la condición de independencia es difícil. El siguiente Lema asegura que esta es *equivalente a una*

propiedad de factorización de la densidad conjunta como producto de densidades marginales que es fácil de verificar.

Lemma 2.11. *Las siguientes propiedades son equivalentes para un vector (X,Y) aleatorio con densidad $f_{(X,Y)}(x,y)$ absolutamente continua:*

(1) Las componentes X,Y del vector (X,Y) son variables aleatorias independientes.
(2) La siguiente igualdad ocurre entre las densidades acumuladas

$$F_{(X,Y)}(\beta_1,\beta_2) = F_X(\beta_1)\cdot F_Y(\beta_2)$$

para todo β_1,β_2
(3) Si $f_X(x)$ y $f_Y(y)$ son las densidades marginales de (X,Y) entonces

$$f_{(X,Y)}(x,y) = f_X(x)\cdot f_Y(y)$$

para todos $(x,y)\in\mathbb{R}^2$

2.4. **Distribuciones conjuntas de vectores aleatorios.** Esta sección reúne algunos ejemplos de usos de densidades conjuntas.

Ejemplo 2.12. Suponga que X e Y son variables aleatorias normales standard e INDEPENDIENTES. Calcule la densidad de X^2+Y^2. Sea $S := X^2+Y^2$. Como X e Y son independientes, la densidad conjunta de (X,Y) es

$$f_{(X,Y)}(x,y) = \frac{1}{2\pi}e^{-(x^2+y^2)/2}.$$

Para $s\geqslant 0$, usando coordenadas polares $x = r\cos\theta$, $y = r\sin\theta$ (jacobiano r):

$$F_S(s) = \mathbb{P}\{X^2+Y^2\leqslant s\} = \int_0^{2\pi}\int_0^{\sqrt{s}} \frac{1}{2\pi}e^{-r^2/2}\,r\,dr\,d\theta = 1-e^{-s/2}.$$

Diferenciando obtenemos la densidad

$$f_S(s) = \frac{1}{2}e^{-s/2},\quad s>0$$

(es $f_S(s)=0$ para $s<0$): S tiene distribución exponencial de tasa $1/2$, equivalente a una χ^2 con 2 grados de libertad.

Ejemplo 2.13. Suponga que X e Y son variables aleatorias normales standard e INDEPENDIENTES. Cómo es la densidad conjunta de las coordenadas polares (R,θ) del punto (X,Y)? Consideremos la transformación $(x,y) = (r\cos\theta, r\sin\theta)$ con $r\geqslant 0$ y $\theta\in[0,2\pi)$, cuyo jacobiano es

$$J = \begin{vmatrix} \cos\theta & -r\sin\theta \\ \sin\theta & r\cos\theta \end{vmatrix} = r.$$

Por la fórmula de cambio de variables la densidad conjunta de (R,θ) es

$$f_{(R,\theta)}(r,\theta) = f_{(X,Y)}(r\cos\theta, r\sin\theta)\,r = \frac{r}{2\pi}e^{-r^2/2}.$$

Notar que R y θ resultan independientes: la densidad se factoriza en $f_R(r) = re^{-r^2/2}$ (distribución de Rayleigh) y $f_\theta(\theta) = \frac{1}{2\pi}$ (uniforme en $[0,2\pi)$).

Ejemplo 2.14. Suponga que X e Y son variables aleatorias normales standard e INDEPENDIENTES. Cómo es la densidad conjunta del vector aleatorio (Z,W) definido mediante el producto de matrices

$$\begin{pmatrix} Z \\ W \end{pmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} X \\ Y \end{pmatrix}$$

donde a,b,c,d son números reales dados tales que la transformación lineal es invertible ($ad-bc \neq 0$). La transformación lineal $(X,Y) \mapsto (Z,W)$ es invertible; su inversa es

$$x = \frac{dz-bw}{ad-bc}, \qquad y = \frac{-cz+aw}{ad-bc}$$

y su jacobiano es $|ad-bc|$. Por la fórmula de cambio de variables la densidad conjunta de (Z,W) es

$$f_{(Z,W)}(z,w) = \frac{1}{2\pi|ad-bc|} \exp\left(-\frac{(dz-bw)^2+(-cz+aw)^2}{2\,(ad-bc)^2}\right),$$

es decir, (Z,W) tiene una distribución gaussiana bivariable con medias nulas.

3. Valor esperado, varianza, momentos y su función generadora

Definición 3.1. Si $(X_1,\ldots,X_n)$ es un vector aleatorio en $\mathbb{R}^n$ con densidad absolutamente continua y $g:\mathbb{R}^n \to \mathbb{R}$ es una función escalar definimos el *valor esperado* o *valor promedio* de g en $(X_1,\ldots,X_n)$ mediante la fórmula

$$\mathbb{E}[g(X_1,\ldots,X_n)] := \int\int\cdots\int_{\mathbb{R}^n} g(x_1,\ldots,x_n) f_{(X_1,\ldots,X_n)}(x_1,\ldots,x_n)\,dx_1dx_2\ldots dx_n$$

En particular, si X es una variable aleatoria en $1D$ lo anterior nos permite definir $\mathbb{E}[X]$ y $\mathrm{Var}(X) := \mathbb{E}[(X-\mu)^2]$ donde $\mu := \mathbb{E}[X]$. Más generalmente el k-ésimo momento de X está dado por $\mu_k := \mathbb{E}[X^k]$. El vector de momentos es una manera de codificar el comportamiento de una distribución de probabilidad.

El siguiente Lema contiene las propiedades principales de valor esperado y varianza

Lemma 3.2. *Si X,Y son variables aleatorias en $\mathbb{R}$ y a,b números reales entonces se cumplen las siguientes propiedades:*

(1) Linealidad de la esperanza $\mathbb{E}[aX+Y] = a\mathbb{E}[X]+\mathbb{E}[Y]$

(2) Si X,Y son variables aleatorias INDEPENDIENTES entonces $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.

(3) No-linealidad de la varianza

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

(4) $\mathrm{Var}(aX+b) = a^2\mathrm{Var}(X)$

(5) Si X,Y son variables aleatorias INDEPENDIENTES entonces

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X)+\mathrm{Var}(Y)$$

Definición 3.3. Si X es una variable aleatoria en $\mathbb{R}$ su *función generadora de momentos* está dada por

$$m_X(t) := \mathbb{E}[e^{tX}]$$

Se llama función generadora de momentos pues tiene la propiedad de que mediante diferenciación nos permite determinar los momentos superiores de una variable aleatoria. Concretamente si derivamos $m_X(t)$ respecto a la variable t k-veces y luego la evaluamos en $t = 0$ obtenemos

$$\frac{d^k}{dt^k}(m_X(t))|_{t=0} = \mathbb{E}[X^k]$$

Lemma 3.4. *La siguiente tabla contiene las funciones generadoras de momento de las distribuciones más comunes*

Distribución	*Parámetros*	*Densidad* f_X	*Función generadora de momentos* $m_X(t)$
Bernoulli	p	$p^x(1-p)^{1-x}$, $x \in \{0,1\}$	$1-p+pe^t$
Binomial	n, p	$\binom{n}{k} p^k(1-p)^{n-k}$, $k = 0,\ldots,n$	$(1-p+pe^t)^n$
Poisson	λ	$e^{-\lambda}\frac{\lambda^k}{k!}$, $k = 0,1,2,\ldots$	$e^{\lambda(e^t-1)}$
Uniforme	$[a,b]$	$\frac{1}{b-a}\mathbf{1}_{[a,b]}(x)$	$\frac{e^{bt}-e^{at}}{t(b-a)}$
Gaussiana	(μ,σ^2)	$\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$e^{\mu t+\frac{\sigma^2 t^2}{2}}$
Exponencial	λ	$\lambda e^{-\lambda x}\mathbf{1}_{x\geqslant 0}$	$\frac{\lambda}{\lambda-t}$, $t<\lambda$

3.1. **Concentración de la medida.** De la definición se sigue que la varianza de una variable aleatoria X es idéntica a cero precisamente cuando X es determinista (i.e. caso en el que coincide idénticamente con su propio valor esperado). En esta sección estudiamos un primer resultado de concentración que asegura que las variables aleatorias con poca varianza están cerca de su media.

Lemma 3.5. *Desigualdad de Markov Sea X una variable aleatoria positiva con $\mathbb{E}[X] < \infty$ y sea $t > 0$ un número real. Tenemos la desigualdad*

$$\mathbb{P}\{X \geqslant t\} \leqslant \frac{\mathbb{E}[X]}{t}$$

Teorema 3.6. *Desigualdad de Chebyshev Si X es una variable aleatoria con $\mathrm{Var}(X) < \infty$ entonces para todo $a > 0$ se tiene la desigualdad*

$$\mathbb{P}\{|X-\mu| \geqslant a\} \leqslant \frac{\mathrm{Var}(X)}{a^2}$$

Ejemplo 3.7. *Por qué medir es posible?* Sean $X_1,\ldots,X_n$ una colección de variables aleatorias INDEPENDIENTES e idénticamente distribuidas. En particular tienen la misma media μ y varianza σ^2. El promedio es la variable aleatoria

$$S_n := \frac{X_1+\cdots+X_n}{n}.$$

De la linealidad del valor esperado concluimos

$$\mathbb{E}[S_n] = \mu$$

y de la independencia sabemos que

$$\mathrm{Var}(S_n) = \frac{\sum_{j=1}^n \mathrm{Var}(X_j)}{n^2} = \frac{\sigma^2}{n}$$

Lo importante es que cuando $n \to \infty$ la varianza $\mathrm{Var}(S_n) \to 0$ luego la variable se concentra alrededor de su media y una sola medición del promedio es, con alta probabilidad, una buena estimación de μ.

Más precisamente, por la desigualdad de Chebyshev sabemos que

$$\mathbb{P}\{|S_n - \mu| \geqslant a\} \leqslant \frac{\sigma^2}{na^2}$$

lo que nos da una idea cuantitativa de la concentración.

Para visualizar la concentración, la figura siguiente muestra la densidad del promedio $S_n = \frac{1}{n}(X_1 + \cdots + X_n)$ de n variables normales estándar $X_j \sim N(0,1)$ para $n = 1, 5, 10, 50$. Como $S_n \sim N(0, 1/n)$, a medida que n crece la densidad se hace más alta y más angosta, concentrándose en torno a 0 (su media).

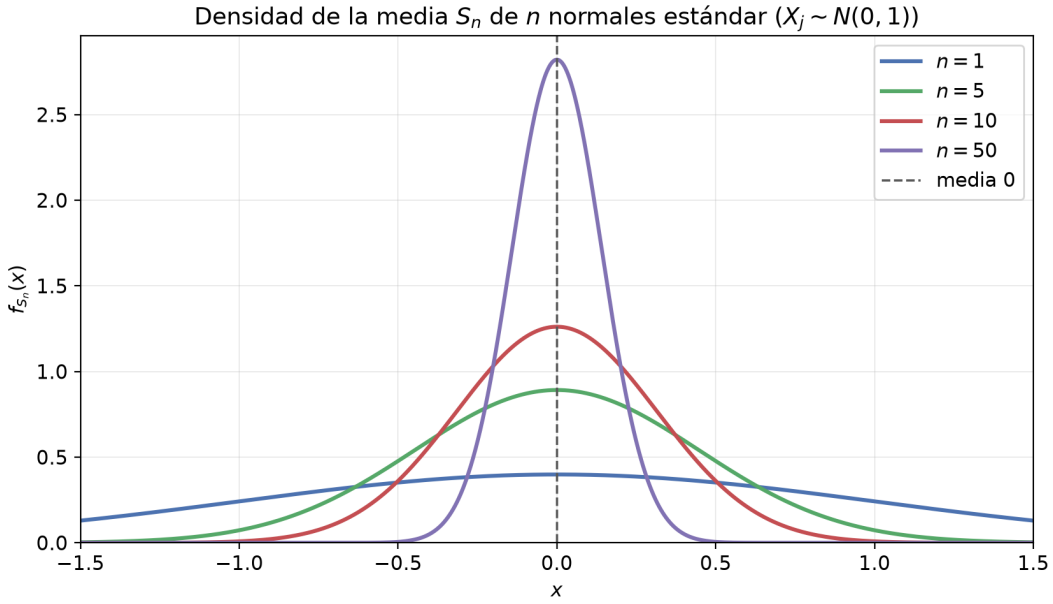


FIGURE 7. Densidad de la media muestral S_n de n normales estándar $X_j \sim N(0,1)$ para $n = 1, 5, 10, 50$. Como $S_n \sim N(0, 1/n)$, al crecer n la distribución se concentra alrededor de su media 0 (menor dispersión).